

# Tarea 2

---

Modelo vectorial y Modelo Big Data

ALUMNO

**Ferrer Cordero José Manuel**

TEMAS

Bases de datos vectoriales ▪ Big Data

## Modelo vectorial

La información se presenta de muchas formas. Parte de la información no está estructurada (como los documentos de texto, los archivos multimedia enriquecidos y el audio) y otra parte está estructurada (como los registros de aplicaciones, las tablas y los gráficos).

Las innovaciones en inteligencia artificial y machine learning (AI/ML) nos permitieron crear un tipo de modelo de ML: modelos de incrustación. Las incrustaciones codifican todos los tipos de datos en vectores que capturan el significado y el contexto de un activo.

Esto nos permite encontrar activos similares mediante la búsqueda de puntos de datos vecinos. Los métodos de búsqueda vectorial permiten experiencias únicas, como tomar una fotografía con el smartphone y buscar imágenes similares.

Las bases de datos vectoriales proporcionan la capacidad de almacenar y recuperar vectores como puntos de alta dimensión. Añaden capacidades adicionales para la búsqueda eficiente y rápida de los vecinos más cercanos en el espacio N-dimensional.

Por lo general, se basan en índices de k vecinos más cercanos (k-nearest neighbor, k-NN) y se crean con algoritmos como los algoritmos Hierarchical Navigable Small World (HNSW) e Inverted File Index (IVF).

Las bases de datos vectoriales proporcionan capacidades adicionales (como la gestión de datos, la tolerancia a errores, la autenticación y el control de acceso) y un motor de consultas.

### Ventajas

- **Búsqueda semántica real:** Encuentra conceptos y significados similares (por ejemplo, relacionar “gato” con “felino”), sin requerir palabras exactas.
- **Manejo de datos no estructurados:** Guarda texto, imágenes, audios y videos transformados en vectores.
- **Ideal para Inteligencia Artificial:** Es clave para potenciar modelos de lenguaje (LLM), motores de recomendación y sistemas de recuperación aumentada (RAG).
- **Gran velocidad:** Realiza búsquedas de vecinos cercanos en espacios de alta dimensión en milisegundos.

### Desventajas

- **Maldición de la dimensionalidad:** Al crecer las dimensiones, los datos se dispersan y el cálculo de distancias se vuelve más lento y costoso.
- **Consultas complejas limitadas:** No son óptimas para operaciones analíticas tradicionales o transacciones complejas, como las garantías ACID de las bases de datos relacionales.
- **Curva de aprendizaje:** Su configuración, afinación de índices y mantenimiento exigen conocimientos especializados.
- **Consumo de recursos:** Requieren alta capacidad de cómputo y memoria RAM para procesar y comparar millones de vectores con precisión.

## Software más utilizado

### Milvus

Diseñado para el ámbito empresarial, es un software de código abierto altamente escalable que procesa miles de millones de vectores en segundos y distribuye el almacenamiento de forma eficiente [Milvus Vector Database].

### Pinecone

Una plataforma en la nube completamente administrada (serverless) que elimina la necesidad de configurar infraestructura física, muy popular por su rapidez de despliegue.

## Modelo Big Data

Big Data se refiere al conjunto de tecnologías, infraestructuras y metodologías diseñadas para capturar, almacenar, procesar y analizar volúmenes de datos tan masivos, rápidos y complejos que las bases de datos tradicionales no pueden gestionarlos.

### Las 5 Vs del Big Data

Su concepto base se define a través de las 5 Vs del Big Data:

**Volumen**, terabytes o petabytes de información;

**Velocidad**, datos generados en tiempo real;

**Variedad**, datos estructurados, semiestructurados y no estructurados;

**Veracidad**, calidad y confiabilidad de los datos;

y **Valor**, el beneficio económico o estratégico que se obtiene al analizarlos.

### Ventajas

- **Toma de decisiones precisa:** Transforma datos brutos en predicciones comerciales basadas en patrones reales y no en suposiciones.
- **Personalización masiva:** Permite entender el comportamiento exacto de millones de clientes para ofrecerles productos a su medida en tiempo real.
- **Eficiencia operativa:** Optimiza cadenas de suministro, detecta cuellos de botella en la producción y previene fallos antes de que ocurran.
- **Innovación de productos:** Facilita la creación de nuevos servicios al identificar necesidades del mercado que antes eran invisibles.

### Desventajas

- **Altos costos iniciales:** Requiere una inversión considerable en infraestructura tecnológica, servidores en la nube y licencias especializadas.
- **Brecha de talento:** Existe una alta escasez mundial de profesionales calificados, como científicos de datos e ingenieros de Big Data.
- **Riesgos de seguridad:** Centralizar volúmenes masivos de información confidencial convierte a las empresas en un blanco atractivo para los ciberataques.

- **Cumplimiento regulatorio:** Validar la privacidad de los datos bajo leyes estrictas (como el RGPD o leyes locales) se vuelve sumamente complejo.

## Dónde se utiliza

- **Sector Financiero:** Se emplea para la detección de fraudes con tarjetas de crédito en milisegundos y el análisis de riesgo crediticio automatizado.
- **Salud y Medicina:** Permite secuenciar el ADN a gran escala, predecir brotes epidemiológicos y acelerar el descubrimiento de nuevos fármacos.
- **Comercio y E-commerce:** Gigantes como Amazon lo usan para gestionar inventarios dinámicos y recomendar productos según el historial de navegación.
- **Entretenimiento y Streaming:** Plataformas como Netflix o Spotify analizan los clics y segundos reproducidos para sugerir contenido personalizado.
- **Logística y Transporte:** Optimiza las rutas de entrega de mercancías en tiempo real considerando el tráfico, el clima y el consumo de combustible.
- **Ciudades Inteligentes:** Gestiona el tráfico urbano mediante sensores públicos y optimiza el consumo de energía en las redes eléctricas.

## Software más utilizado

Las herramientas de Big Data se dividen según la etapa del flujo de datos en la que operan:

### 1. Almacenamiento y Sistemas de Archivos

- **Hadoop (HDFS):** El ecosistema clásico de código abierto que distribuye el almacenamiento de archivos masivos a través de miles de servidores económicos.
- **Amazon S3 / Google Cloud Storage:** Almacenamiento de objetos en la nube, utilizado como la base para construir “Lagos de Datos” (Data Lakes) altamente escalables.

### 2. Procesamiento de Datos (Batch y Streaming)

- **Apache Spark:** El motor de procesamiento en memoria más rápido y popular de la industria. Supera a Hadoop MapReduce y procesa datos en tiempo real o en lotes.
- **Apache Flink:** Diseñado específicamente para el procesamiento de flujos de datos (streaming) continuos de ultra baja latencia.

### 3. Bases de Datos NoSQL y Motores Analíticos

- **Apache Cassandra:** Base de datos NoSQL distribuida, famosa por su alta disponibilidad y capacidad para escribir volúmenes masivos de datos sin caídas.
- **ClickHouse / Snowflake:** Almacenes de datos (Data Warehouses) analíticos orientados a columnas, optimizados para ejecutar consultas SQL sobre miles de millones de filas en segundos.

### 4. Orquestación e Ingesta de Datos

- **Apache Kafka:** Un sistema de mensajería distribuida que actúa como la “autopista central” por donde viajan millones de eventos de datos por segundo.
- **Apache Airflow:** Herramienta utilizada para programar, organizar y monitorear flujos de trabajo complejos de datos (tuberías ETL).