

Modelos vectoriales y Big Data

García Olvera José Ignacio

Introducción

A continuación se presenta la investigación de dos enfoques utilizados en el manejo moderno de datos: el **modelo vectorial** y el **modelo Big Data**. Para cada uno se incluye primero una definición formal y después una explicación sencilla, seguidas de sus características, ventajas, desventajas, casos de uso y el software que los implementa.

1 Modelo vectorial

Definición formal

Un modelo de base de datos vectorial es un sistema de almacenamiento diseñado para representar datos no estructurados (texto, imágenes, audio o video) mediante *embeddings*: vectores numéricos de alta dimensionalidad generados por modelos de aprendizaje automático, que capturan las relaciones semánticas del contenido original. En lugar de recuperar información mediante coincidencia exacta de valores, estos sistemas emplean algoritmos de búsqueda por similitud (como la distancia coseno o la distancia euclidiana) y estructuras de indexación aproximada de vecinos más cercanos, entre ellas HNSW (*Hierarchical Navigable Small World*), IVF (*Inverted File Index*) o LSH (*Locality-Sensitive Hashing*), con el fin de encontrar de forma eficiente los elementos más cercanos a un vector de consulta dentro de un espacio de millones de dimensiones.

Explicación sencilla

En términos simples, un modelo vectorial convierte cualquier tipo de contenido (una palabra, una foto, una canción) en una especie de “huella numérica” que representa su significado. Esa huella se coloca en un mapa imaginario donde las cosas parecidas quedan cerca unas de otras. Cuando se hace una búsqueda, el sistema no busca una coincidencia exacta, sino los puntos más cercanos en ese mapa; por eso es capaz de encontrar resultados relacionados aunque no se usen las mismas palabras. Esta idea es la base de tecnologías como los buscadores semánticos, los sistemas de recomendación y los chatbots basados en inteligencia artificial.

Características

- Almacena la información como vectores (embeddings) generados por modelos de aprendizaje automático.

- Realiza búsquedas por similitud en lugar de coincidencia exacta.
- Utiliza métricas de distancia como la coseno, la euclidiana o el producto punto.
- Emplea estructuras de indexación aproximada (HNSW, IVF, LSH) para acelerar la búsqueda en espacios de alta dimensión.
- Suele integrarse con *pipelines* de inteligencia artificial y modelos de lenguaje.

Ventajas

- Permite búsquedas semánticas: encuentra resultados por significado, no solo por texto exacto.
- Es la base técnica de sistemas de recomendación y de *Retrieval-Augmented Generation* (RAG) para modelos de lenguaje.
- Escala bien para grandes volúmenes de datos no estructurados.
- Funciona con distintos tipos de contenido: texto, imagen, audio y video.

Desventajas

- Los resultados son aproximados, no exactos, lo que implica un compromiso entre velocidad y precisión.
- Requiere generar los embeddings previamente mediante un modelo de aprendizaje automático, lo que añade complejidad al flujo de datos.
- El costo computacional puede ser alto conforme crece la dimensionalidad de los vectores.
- Es un modelo menos interpretable que las consultas tradicionales basadas en SQL.

Casos de uso

- Búsqueda semántica en motores de búsqueda y bases de conocimiento.
- Sistemas de recomendación de productos, música o contenido.
- Recuperación de información para chatbots y asistentes basados en modelos de lenguaje (RAG).
- Búsqueda de imágenes o audio similares.
- Detección de fraude y anomalías por similitud de patrones.

Software que lo implementa

Pinecone, Milvus, Weaviate, Chroma, Qdrant, FAISS (biblioteca de Facebook AI) y la extensión pgvector para PostgreSQL.

2 Modelo Big Data

Definición formal

El modelo Big Data no constituye un modelo de datos único, sino un paradigma arquitectónico orientado al almacenamiento, procesamiento y análisis de conjuntos de datos que superan la capacidad de las herramientas tradicionales de gestión de bases de datos, ya sea por su volumen, la velocidad a la que se generan o la heterogeneidad de sus formatos. Este paradigma se apoya en sistemas de cómputo distribuido que combinan distintos modelos NoSQL (documental, columnar, clave-valor o de grafos) y en arquitecturas de procesamiento por lotes (*batch*) o en tiempo real (*streaming*), habitualmente descritas mediante las cinco dimensiones o “V’s”: volumen, velocidad, variedad, veracidad y valor.

Explicación sencilla

Big Data no es un tipo de base de datos como tal, sino una forma de organizarse cuando hay demasiada información para que la maneje un solo servidor. Es la diferencia entre guardar diez recibos en una carpeta y recibir diez millones de recibos por segundo desde todo el mundo: en ese segundo caso se necesita repartir el trabajo entre muchas computadoras que colaboren entre sí. Para explicarlo se suelen usar las llamadas “5 V”: hay muchísimos datos (volumen), llegan muy rápido (velocidad), vienen en formatos distintos como texto, imagen o video (variedad), no siempre son confiables (veracidad) y solo sirven si se logran convertir en algo útil (valor).

Características

- Arquitectura distribuida y escalable horizontalmente en clústeres de servidores.
- Se describe habitualmente mediante las 5 V’s: volumen, velocidad, variedad, veracidad y valor.
- Combina procesamiento por lotes (*batch*) y procesamiento en tiempo real (*streaming*).
- Suele apoyarse en varios modelos NoSQL (documental, columnar, clave-valor, grafos) según la necesidad.
- Emplea arquitecturas como Data Lake, Data Warehouse o Data Lakehouse para organizar el almacenamiento.

Ventajas

- Permite procesar volúmenes de datos que serían inmanejables en un sistema tradicional.
- Habilita análisis y toma de decisiones en tiempo real.
- Es escalable de forma económica mediante hardware distribuido.
- Da flexibilidad para trabajar con datos estructurados, semiestructurados y no estructurados a la vez.

Desventajas

- Requiere infraestructura y conocimientos técnicos especializados.
- La calidad y gobernanza de los datos son más difíciles de garantizar a gran escala.
- El procesamiento por lotes puede introducir latencia cuando se necesita respuesta inmediata.
- Los costos de implementación y mantenimiento pueden ser elevados.

Casos de uso

- Analítica de negocio (*Business Intelligence*) a gran escala.
- Procesamiento de datos de sensores e Internet de las Cosas (IoT).
- Análisis de registros (*logs*) y monitoreo de sistemas.
- Detección de fraude en tiempo real en el sector financiero.
- Sistemas de recomendación masivos en plataformas digitales.

Software que lo implementa

Apache Hadoop, Apache Spark, Apache Kafka, Apache Flink, Apache Hive, Google BigQuery y Databricks.