

Nombre del alumno: Gonzalez Villegas Ellyoth

Nombre del profesor: Fernando Arreola Franco

Materia: Bases de Datos

Tarea #2

Modelo vectorial

Características

El modelo vectorial es una forma de representar información mediante vectores, es decir, conjuntos ordenados de valores numéricos. Cada elemento del vector representa una característica o atributo de un dato.

Este tipo de representación es muy utilizada cuando se necesita comparar datos, encontrar qué tan parecidos son o realizar operaciones matemáticas con ellos.

Actualmente se utiliza bastante en áreas como inteligencia artificial, aprendizaje automático, reconocimiento de imágenes, procesamiento de lenguaje natural y sistemas de recomendación.

Ventajas

- Permite representar información de manera numérica.
- Facilita la comparación entre diferentes datos.
- Es adecuado para realizar cálculos matemáticos.
- Funciona bien con grandes cantidades de información.
- Es muy utilizado en inteligencia artificial y Machine Learning.
- Permite encontrar datos que tienen características similares.

Desventajas

- La información original puede perder parte de su significado al convertirla en números.
- Los vectores pueden llegar a ser muy grandes cuando representan información compleja.
- Se necesita un método adecuado para convertir los datos originales en vectores.
- Las operaciones pueden consumir muchos recursos cuando se manejan millones de vectores.
- No siempre es la mejor forma de representar información que tiene muchas relaciones entre sí.

Caso de uso

Un ejemplo muy común son los motores de búsqueda y sistemas de recomendación.

Por ejemplo, una tienda en línea puede convertir las características de sus productos en vectores y compararlos con los productos que anteriormente ha buscado o comprado un usuario. De esta manera puede recomendar productos similares.

Software de implementación

- FAISS
- Milvus
- Pinecone
- Weaviate
- Qdrant
- Chroma

Modelos de Big Data

Modelo distribuido

Características

En este modelo los datos y el procesamiento se distribuyen entre varias computadoras o servidores, en lugar de depender de una sola máquina.

Cada equipo puede encargarse de una parte de los datos o del procesamiento. Después, los resultados se pueden combinar.

Esto permite trabajar con cantidades de información mucho mayores de las que podría manejar una sola computadora.

Ventajas

- Permite trabajar con grandes cantidades de datos.
- Se puede aumentar la capacidad agregando más equipos.
- Si un servidor falla, otros pueden continuar trabajando dependiendo del sistema.
- Permite procesar diferentes partes de los datos al mismo tiempo.
- Puede reducir el tiempo necesario para procesar grandes cantidades de información.

Desventajas

- La administración del sistema es más complicada.
- Requiere varias máquinas o servidores.
- La comunicación entre los equipos puede generar problemas.
- La configuración y mantenimiento pueden ser costosos.

Caso de uso

Se utiliza para procesar grandes cantidades de información, análisis de datos, aplicaciones web a gran escala y procesamiento de información generada por millones de usuarios.

Software de implementación

- Apache Hadoop
- Apache Spark
- Apache Flink

Modelo de procesamiento por lotes

Características

En este modelo los datos se acumulan durante cierto tiempo y después se procesan en grupos o lotes.

No es necesario procesar cada dato en el momento en que llega. Por ejemplo, una empresa puede acumular las ventas de todo el día y procesarlas durante la noche para generar reportes.

Ventajas

- Es eficiente para grandes cantidades de datos.
- Puede aprovechar mejor los recursos disponibles.
- Es adecuado para procesos que no necesitan resultados inmediatos.
- Permite automatizar tareas de procesamiento.

Desventajas

- Los resultados no están disponibles inmediatamente.
- No es adecuado para situaciones que necesitan información en tiempo real.
- Si ocurre un problema durante el procesamiento, puede ser necesario volver a procesar parte del lote.

Caso de uso

Se utiliza para generación de reportes, análisis de ventas, procesamiento de registros, respaldos y procesamiento de información histórica.

Software de implementación

- Apache Hadoop
- Apache Spark
- Apache Hive

Modelo de procesamiento en tiempo real

Características

En este modelo los datos se procesan prácticamente en el momento en que se generan.

Es útil cuando una empresa o sistema necesita reaccionar rápidamente ante nuevos datos.

Por ejemplo, un banco puede analizar una transacción inmediatamente para detectar si existe alguna actividad sospechosa.

Ventajas

- Permite obtener información rápidamente.
- Ayuda a tomar decisiones en poco tiempo.
- Es útil para detectar eventos o problemas inmediatamente.
- Puede analizar grandes cantidades de datos que llegan constantemente.

Desventajas

- Es más complicado de implementar.
- Puede necesitar una infraestructura más costosa.
- Requiere sistemas capaces de procesar información continuamente.
- Los errores pueden afectar los datos que se están procesando en ese momento.

Caso de uso

Se utiliza en detección de fraudes, monitoreo de sistemas, aplicaciones financieras, sensores, redes sociales y análisis de datos en tiempo real.

Software de implementación

- Apache Kafka
- Apache Flink
- Apache Storm
- Spark Streaming

Modelo Data Lake

Características

Un Data Lake es un sistema que permite almacenar grandes cantidades de datos en su forma original, sin necesidad de organizarlos completamente antes de guardarlos.

Puede almacenar datos estructurados, semiestructurados y no estructurados, como bases de datos, documentos, imágenes, videos y registros.

Los datos pueden organizarse y analizarse posteriormente cuando sea necesario.

Ventajas

- Puede almacenar grandes cantidades de información.
- Permite guardar diferentes tipos de datos.
- Es flexible porque los datos no necesitan estar completamente estructurados desde el principio.
- Puede utilizarse para análisis posteriores y proyectos de inteligencia artificial.

Desventajas

- Si no se administra correctamente, puede convertirse en un lugar desordenado donde sea difícil encontrar información.
- La seguridad y administración de los datos pueden ser complicadas.
- Puede ser difícil saber qué tan confiable es cada dato si no existe un buen control.

Caso de uso

Se utiliza cuando una organización necesita almacenar información de diferentes fuentes para posteriormente realizar análisis, inteligencia artificial, Machine Learning o Business Intelligence.

Software de implementación

- Amazon S3
- Azure Data Lake Storage
- Google Cloud Storage
- Hadoop HDFS

Modelo Data Warehouse

Características

Un Data Warehouse es un sistema diseñado principalmente para almacenar información organizada y utilizarla para realizar análisis y generar reportes.

A diferencia de un Data Lake, normalmente los datos se procesan y organizan antes de almacenarse para facilitar su consulta.

Ventajas

- Facilita la creación de reportes.

- Permite analizar información histórica.
- Los datos están organizados.
- Tiene buen rendimiento para consultas analíticas.
- Ayuda en la toma de decisiones de una empresa.

Desventajas

- Puede ser costoso de implementar y mantener.
- Los datos necesitan pasar por procesos de preparación.
- Es menos flexible que un Data Lake para almacenar datos sin estructura.
- Puede requerir bastante tiempo para diseñar correctamente la estructura.

Caso de uso

Se utiliza principalmente en empresas para analizar ventas, clientes, finanzas, inventarios, rendimiento y otros indicadores importantes.

Software de implementación

- Snowflake
- Google BigQuery
- Amazon Redshift
- Microsoft Azure Synapse Analytics
- Oracle Autonomous Data Warehouse