

Tarea 2: Investigar Las características, Ventajas, Desventajas, Casos de uso y Softwares que utilizan Los Modelos de Datos vectorial y Modelo Big Data

Bases de Datos Teoria
Facultad de Ingeniería, UNAM
Daniel Angel Martínez Miranda 317252866
Profesor: Ing. Fernando Arriola Grupo:01

24 de agosto de 2026

1. Introducción

Este es mi primer documento compilado de forma nativa en mi partición de Ubuntu. El objetivo es cumplir con la tarea 2, subirla al github mediante un pull request y comprobar que el entorno de $\text{\LaTeX}$ funciona correctamente en mi laptop listo para lo que el profesor dijo que usaremos próximamente creo que en el proyecto.

2. Modelo de Datos Vectorial

Este modelo ha explotado en popularidad recientemente gracias a la Inteligencia Artificial Generativa y los Modelos de Lenguaje Grande (LLMs). En lugar de guardar datos en tablas o documentos, guarda la información como vectores matemáticos en un espacio de múltiples dimensiones.

3. Qué es una base de datos vectorial?

La información se presenta de muchas formas. Parte de la información no está estructurada (como los documentos de texto, los archivos multimedia enriquecidos y el audio) y otra parte está estructurada (como los registros de aplicaciones, las tablas y los gráficos). Las innovaciones en inteligencia artificial y machine learning (AI/ML) nos permitieron crear un tipo de modelo de ML: modelos de incrustación. Las incrustaciones codifican todos los tipos de datos en vectores que capturan el significado y el contexto de un activo. Esto nos permite encontrar activos similares mediante la búsqueda de puntos de datos vecinos. Los métodos de búsqueda vectorial permiten experiencias únicas, como tomar una fotografía con el smartphone y buscar imágenes similares.

Las bases de datos vectoriales proporcionan la capacidad de almacenar y recuperar vectores como puntos de alta dimensión. Añaden capacidades adicionales para la búsqueda eficiente y rápida de los vecinos más cercanos en el espacio N-dimensional. Por lo general, se basan en índices de k vecinos más cercanos (k-nearest neighbor, k-NN) y se crean con algoritmos como los algoritmos Hierarchical Navigable Small World (HNSW) e Inverted File Index (IVF). Las bases de datos vectoriales proporcionan capacidades adicionales (como la gestión de datos, la tolerancia a errores, la autenticación y el control de acceso) y un motor de consultas.

4. ¿Por qué son importantes las bases de datos vectoriales?

Sus desarrolladores pueden indexar los vectores generados por las incrustaciones en una base de datos vectorial. Esto les permite encontrar activos similares consultando vectores vecinos.

Las bases de datos vectoriales proporcionan un método para hacer operativos los modelos de incrustación. El desarrollo de aplicaciones es más productivo con capacidades de base de datos como la gestión de recursos, los controles de seguridad, la escalabilidad, la tolerancia a errores y la recuperación eficiente de la información mediante lenguajes de consulta sofisticados.

En última instancia, las bases de datos vectoriales permiten a los desarrolladores crear experiencias de aplicaciones únicas. Por ejemplo, los usuarios pueden tomar fotografías en sus smartphones para buscar imágenes similares.

Los desarrolladores pueden usar otros tipos de modelos de aprendizaje automático para automatizar la extracción de metadatos a partir de contenidos como imágenes y documentos escaneados. Pueden indexar metadatos junto con vectores para permitir la búsqueda híbrida tanto en palabras clave como en vectores. También pueden fusionar la comprensión semántica con el ranking de relevancia para mejorar los resultados de búsqueda.

Las innovaciones en la inteligencia artificial (IA) generativa han introducido nuevos tipos de modelos, como ChatGPT, que pueden generar texto y gestionar conversaciones complejas con humanos. Algunos pueden funcionar en múltiples modalidades; por ejemplo, algunos modelos permiten a los usuarios describir un paisaje y generar una imagen que se ajuste a la descripción.

Sin embargo, los modelos generativos son propensos a las alucinaciones, que podrían, por ejemplo, provocar que un chatbot engañe a los usuarios. Las bases de datos vectoriales pueden complementar los modelos de IA generativa. Pueden proporcionar una base de conocimientos externa para los chatbots con IA generativa y ayudar a garantizar que proporcionen información confiable.

5. ¿Cómo se usan las bases de datos vectoriales?

Las bases de datos vectoriales se utilizan normalmente para impulsar casos de uso de búsquedas vectoriales, como la búsqueda visual, semántica y multimodal. Más recientemente, se han combinado con modelos de texto de inteligencia artificial (IA) generativa para crear agentes inteligentes que proporcionan experiencias de búsqueda conversacional.

El proceso de desarrollo comienza con la creación de un modelo de incrustación diseñado para codificar imágenes de productos similares a un corpus en vectores. El proceso de importación de datos también se denomina hidratación de datos. El desarrollador de la aplicación ahora puede usar la base de datos para buscar productos similares codificando una imagen del producto y utilizando el vector para buscar imágenes similares.

Dentro del modelo, los índices de k vecino más cercano (k-nearest neighbor, k-NN) proporcionan una recuperación eficiente de los vectores y aplican una función de distancia como el coseno para clasificar los resultados por similitud.

6. ¿Quién usa las bases de datos vectoriales?

Las bases de datos vectoriales son para desarrolladores que desean crear experiencias basadas en búsquedas vectoriales. Un desarrollador de aplicaciones puede usar modelos de código abierto, herramientas de aprendizaje automático (ML) automatizado y servicios de modelos básicos para generar incrustaciones e hidratar una base de datos vectorial. Esto requiere una experiencia mínima en ML.

Un equipo de científicos e ingenieros de datos puede crear incrustaciones ajustadas por expertos y ponerlas en funcionamiento a través de una base de datos vectorial. Esto puede ayudarlos a ofrecer una solución de inteligencia artificial (IA) con mayor rapidez.

Los equipos de operaciones se benefician de la gestión de las soluciones como cargas de trabajo de bases de datos conocidas. Pueden utilizar las herramientas y los manuales de estrategias existentes.

7. ¿Cuáles son los beneficios de las bases de datos vectoriales?

Las bases de datos vectoriales permiten a los desarrolladores innovar y crear experiencias únicas impulsadas por la búsqueda vectorial. Pueden acelerar el desarrollo de aplicaciones de inteligencia artificial (IA) y simplificar la operacionalización de las cargas de trabajo de aplicaciones impulsadas por la IA.

Las bases de datos vectoriales ofrecen una alternativa a la creación sobre índices simples de k vecinos más cercanos (K-nn). Ese tipo de índice requiere una gran cantidad de experiencia e ingeniería adicionales para su uso, ajuste y puesta en funcionamiento.

Una buena base de datos vectorial proporciona a las aplicaciones una base mediante funciones como la gestión de datos, la tolerancia a errores, las funciones de seguridad críticas y un motor de consultas. Estas capacidades permiten a los usuarios poner en funcionamiento sus cargas de trabajo para simplificar el escalado, mantener una alta escalabilidad y cumplir con los requisitos de seguridad.

Capacidades como el motor de consultas y los SDK simplifican el desarrollo de aplicaciones. También permiten a los desarrolladores realizar consultas más avanzadas (como buscar y filtrar) en los metadatos como parte de una búsqueda de K-nn.

8. Características

Almacenamiento de Embeddings: que son representaciones numericas (arrays de números flotantes) de datos no estructurados como texto, imágenes o audio. Búsqueda por Similitud: No busca coincidencias exactas (como el WHERE en SQL), sino "Vecinos Más Cercanos" (Nearest Neighbors). Busca qué vector se parece más a otro usando cálculos matemáticos como la Similitud del Coseno o la Distancia Euclidiana.

Alta Dimensionalidad: Un solo dato (ej. una frase) puede tener cientos o miles de dimensiones (números) que representan su significado.

9. ventajas

Increíblemente rápida para recuperar información no estructurada basándose en el contexto o el significado, no en palabras clave exactas.

Se integra de forma nativa con modelos de Machine Learning y Redes Neuronales.

Permite darle "memoria a largo plazo." a los asistentes de IA.

10. Desventajas

Es ineficiente para consultas transaccionales clásicas (ej. dame todas las ventas de enero que superen los 500). Requiere un paso previo computacionalmente costoso: convertir los datos originales en vectores usando un modelo de ML (embedding) antes de guardarlos.

Son herramientas relativamente nuevas, por lo que los estándares aún están evolucionando.

11. Casos de uso

Motores de búsqueda semántica: Buscar en documentos por el significado de la pregunta, no por palabras exactas.

Sistemas de recomendación visuales: "Encuentra ropa parecida a la de esta foto".

Generación Aumentada por Recuperación (RAG): Darle documentos privados a una IA para que responda preguntas basándose exclusivamente en ellos.

Detección de anomalías y fraudes basándose en patrones de comportamiento.

12. Software

(Motores Vectoriales): Milvus, Pinecone, Weaviate, Qdrant, ChromaDB, y extensiones como pgvector (para PostgreSQL).

13. Modelo Big Data

Big data se puede describir en torno a desafíos de administración de datos que, debido al incremento en el volumen, la velocidad y la variedad de los datos, no se puede resolver con las bases de datos tradicionales. Aunque existen numerosas definiciones de big data, la mayoría incluyen el concepto de lo que se conoce como las “tres V” de los big data:

Volumen: va desde terabytes hasta petabytes de datos

Variedad: incluye datos de una amplia variedad de orígenes y formatos (p. ej., registros web, interacciones en las redes sociales, transacciones en línea y de comercio electrónico, transacciones financieras, etc.)

Velocidad: cada vez más, las empresas tienen requisitos exigentes desde el momento en que se generan los datos al momento en que se entrega información procesable a los usuarios. Por lo tanto, es necesario recopilar, almacenar, procesar y analizar los datos en periodos relativamente cortos de tiempo, que van desde una vez al día a en tiempo real. Más que un solo modelo, Big Data se refiere a un ecosistema y arquitecturas diseñadas para manejar las 3 V (Volumen, Velocidad y Variedad) que sobrepasan las capacidades de las bases de datos tradicionales.

14. Características

Procesamiento Distribuido: Divide archivos gigantescos y tareas computacionales en miles de fragmentos pequeños, procesándolos en paralelo a través de grupos (clusters) de computadoras.

Esquema al Leer (Schema-on-Read): A diferencia de SQL donde defines la tabla antes de guardar el dato (Schema-on-Write), en Big Data puedes aventar los datos crudos (JSON, logs, videos) al almacenamiento y aplicarles una estructura hasta el momento en que los vas a consultar.

Tolerancia a fallos: Si un nodo (computadora) en el cluster se apaga o se daña, el sistema automáticamente redirige el trabajo a otro nodo sin perder información, gracias a la replicación de datos.

15. Ventajas

Escalabilidad horizontal infinita: Si necesitas más poder, simplemente agregas más servidores económicos al cluster en lugar de comprar un “súper servidor” carísimo.

Flexibilidad absoluta: Puede ingerir y almacenar cualquier tipo de dato (estructurado, semi-estructurado y no estructurado) en su estado natural (conocido como Data Lake).

Permite descubrir patrones ocultos en años históricos de información a nivel petabyte.

16. Desventajas

Alta complejidad de instalación, configuración y mantenimiento. Requiere perfiles especializados (Data Engineers).

Latencia: No están diseñados para respuestas en tiempo real (milisegundos) para un solo usuario, sino para procesar lotes masivos de información (Batch Processing) que pueden tardar minutos u horas.

Los costos de infraestructura en la nube pueden dispararse si los procesos no se optimizan correctamente.

17. Casos de uso

Análisis del genoma humano e investigación científica.

Procesamiento de telemetría masiva (ej. millones de sensores de dispositivos IoT en fábricas o ciudades inteligentes).

Análisis de logs de servidores web a nivel global para optimización de redes.

Entrenamiento de modelos fundacionales de Inteligencia Artificial.

18. Software

Almacenamiento: Hadoop Distributed File System (HDFS), Amazon S3.

Procesamiento: Apache Spark, Apache Flink, MapReduce.

Bases de Datos analíticas sobre Big Data: Apache Hive, Databricks, Snowflake.