

Tarea 2: Modelo Vectorial y Big Data

1. Modelos de datos Vectorial y Big Data

1.1. Modelo vectorial

- **Características:** Almacena y gestiona datos en forma de vectores numéricos de alta dimensión (llamados embeddings). Utiliza algoritmos de búsqueda por similitud vectorial (como KNN o ANN) en lugar de coincidencias exactas.
- **Ventajas:** Permite realizar búsquedas semánticas (por significado, contexto, descripción) eficientes sobre datos no estructurados (texto, imágenes, audio) y es ideal para integrar con modelos de inteligencia artificial.
- **Desventajas:** Alto consumo de memoria RAM, costo computacional elevado para la construcción de los embeddings y los índices vectoriales. Las búsquedas pueden ser lentas cuando la cantidad de datos es demasiado grande.
- **Caso de uso:** Generación aumentada por recuperación (RAG) en IAs (sistema que permite que una IA busque rápidamente contenido específico en una gran cantidad de archivos), búsqueda por similitud de imágenes o audio, y sistemas de recomendación.
- **Software que lo implementa:** Para uso en servidor/empresarial: Elastic Search, Pinecone, Milvus, Qdrant, Chroma. De forma local/para consumidores: Apple Siri AI, Apple Photos.

1.2. Modelo de datos para Big Data

- **Características:** Diseñado para gestionar masivos volúmenes de datos distribuidos en un grupo distribuido de computadores, soportando alta velocidad de entrada/salida, y procesamiento paralelo. Existen varias implementaciones, pero al priorizarse un rápido tiempo de procesamiento y baja latencia, es común usar modelos NoSQL o documentales.
- **Ventajas:** Gran capacidad de escalado horizontal, alta disponibilidad, tolerancia a fallos y capacidad para procesar datos estructurados, semiestructurados y no estructurados.
- **Desventajas:** Alta complejidad de configuración y mantenimiento, la consistencia de los datos es eventual en lugar de inmediata y necesidad de infraestructura costosa y de alta confiabilidad.

- **Caso de uso:** Procesamiento de secuencias de datos en tiempo real, análisis masivo de datos de métricas de uso, análisis de cantidades masivas de información de sensores.
- **Software que lo implementa:** Apache HBase, Google Bigtable, Databricks